

线性回归 → 局部回归

Problem Setup 1. 已收集到 $(x_i, y_i)_{i=1}^n$ 数据样本，并观察到 x 与 y 之间以某个函数 $y \approx f(x)$ 关系相连。我们想要估计该函数。

回顾参数回归方法：

- 线性回归：如果该函数看起来像线性，我们可以假设 $f(x) = \beta_0 + \beta_1 x$ ，再通过最小化 L_2 损失得到线性模型：

$$\min_{f(x)} \left\{ \sum_{i=1}^n [y_i - f(x_i)]^2 \right\} = \min_{\beta_0, \beta_1} \left\{ \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2 \right\}. \quad (1)$$

- 多项式回归：如果该函数并不像线性，可以假设 $f(x) = \beta_0 + \beta_1 x + \dots + \beta_p x^p$ ，同样最小化 L_2 损失。

无论采用以上哪种方法，最小化 $\min_{f(x)}$ 都可以被化简为求解有限个参数的 $\min_{\beta_0, \dots, \beta_p}$ 问题。我们并没有在无限大的函数空间中寻找最优解，这让计算量始终在可控范围之内 (nice ☺)。而且以上方法一旦得到参数估计 $\hat{\beta}$ ，我们就不再需要原始数据 $(x_i, y_i)_{i=1}^n$ 来做未来预测，仅使用 $\hat{\beta}$ 就可以。这也是他们作为参数方法的好处之一。

1 局部回归方法


我们格外注意损失函数 (1)：参数方法中，它给所有的样本 $i \in [n]$ 都分配了相同的权重。而局部回归方法是另一套逻辑：固定一个点 $x \in \mathbb{R}$ （我们不妨称待估点），我们想估计待估点的函数值 $f(x)$ ，那么我们就去看 x 附近有哪些样本。离 x 越近的样本，我就在损失函数中给他更高的权重。

1.1 k -NN 回归

以上思路最直接的落地方法就是 k -NN，即 $\hat{f}(x) \leftarrow$ 距离待估点最近的 k 个样本的 response 平均值，可以写成：

$$\hat{f}(x) = \sum_{i=1}^n w_i(x) y_i, \quad \text{其中 } w_i(x) = \begin{cases} 1/k & \text{若 } x_i \text{ 是距离 } x \text{ 最近的 } k \text{ 个样本,} \\ 0 & \text{若 } x_i \text{ 不是.} \end{cases}$$

这里的 $w_i(x)$ 正表示第 i 号样本的权重：距离待估点 x 越近，第 i 号样本权重 $w_i(x)$ 更高。



左侧是一个 k -NN 回归的例子。在计算蓝色拟合线 $\hat{f}(x)$ 时，我们别无他法，只能逐点计算：

- 固定待估点 $x = 0.1$ ，找到距离 $x = 0.1$ 最近的 k 个样本，计算他们 response 的平均值，并赋为 $\hat{f}(0.1)$ ；
- 待估点向右移动一点点，比如 $x = 0.2$ ，计算 $\hat{f}(0.2)$ 直到完成整个蓝色曲线。


如果我们固定一个样本 i ，把观察权重 $w_i(x)$ 作为一个 x 的函数来观察，可以发现 $w_1(x), \dots, w_n(x)$ 每一个都不是连续函数。所以他们的线性组合 $\hat{f}(x)$ ，作为 x 的函数，也是不连续的。这也符合我们看到左侧蓝色拟合线有跳点的现象。

所以，我们总结 k -NN 回归：他可以写成 $\hat{f}(x) = \sum_{i=1}^n w_i(x) y_i$ 的形式；拟合 $\hat{f}(x)$ 的计算量很大，因为只能不停移动待估点、一个点一个点地去算；由于 $w_i(x)$ 选择了不连续函数，所以 $\hat{f}(x)$ 也是不连续的。

第一点特征，正是它被归类为局部回归方法的原因——在待估点附近的局部样本拥有更大的权重。后面我们会介绍的几种局部回归都有 $\hat{f}(x) = \sum_{i=1}^n w_i(x)y_i$ 的形式。第二点特征，也会被我们后续介绍的所有 local regression 方法给继承：他们都得逐点计算，比起参数方法，计算量巨大 (bad ☹)。而第三点，是我们为什么要从 k -NN 升级原因——我们想要连续函数！

1.2 核回归 (Kernel Regression)

为了得到一个连续函数 $\hat{f}(x)$ ，在 k -NN 基础上不难发现，我们其实只需要把所有权重函数 $w_i(x)$ 都换成关于 x 连续的就可以。那什么样的函数 $w_i(x)$ 既能够作为权重使用（在 x 附近更大、远离 x 时变小），又能给我们很好的连续性呢？正态分布的钟形曲线！



如果对每个样本 i 都采用权重

$$w_i(x) = \frac{1}{\sqrt{2\pi}} \exp\{-(x - x_i)^2\},$$

那么只有待估点 x 局部附近的样本会有相当高的权重，而很远的样本权重会快速衰减到 0，所以正态密度是非常合适的候选函数。不过我们还不能直接采用它，因为它还有两个缺憾：

- 它并不带来任何参数帮助我们控制权重衰减的速度；
- 这个权重加起来还不是 1，即 $\sum_{i=1}^n w_i(x) \neq 1$ ，所以 $\hat{f}(x) = \sum_{i=1}^n w_i(x)y_i$ 还不能被看作“加权平均”。


但这两个问题并不麻烦，我们把估计器 $\hat{f}(x)$ 设置成下面的形式就可以解决：

$$\hat{f}(x) = \frac{\sum_{i=1}^n \frac{K\left(\frac{x-x_i}{h}\right)}{\sum_{j=1}^n K\left(\frac{x-x_j}{h}\right)} y_i, \quad \text{其中 } K(\cdot) \text{ 是 } N(0,1) \text{ 的密度函数，而窗宽 } h \text{ 是我们预设的一个值。} \quad (2)$$

这样一来，我们实则是把中间比较复杂的那一项看作权重：

$$w_i(x) = \frac{K\left(\frac{x-x_i}{h}\right)}{\sum_{j=1}^n K\left(\frac{x-x_j}{h}\right)}, \quad \text{它的分母其实正是一个归一化，即：现在对于任意待估点 } x \text{ 都有 } \sum_{i=1}^n w_i(x) = 1.$$

窗宽 h 则控制权重的衰减速度：窗宽 h 越大，各个样本的权重 $w_i(x)$ 会变得更加“均匀”（有兴趣的话，写个 simulation 计算看看我说的“均匀”是什么意思），导致拟合曲线整体看起来走势更平缓；而窗宽 h 越小，待估点 x 附近的样本权重会更加突出，导致拟合曲线整体随着数据的弯折更锋利。下面是一张实例图。



其实采用方程 (2) 得到的估计器 $\hat{f}$ 并不一定要局限于 K 为正态密度。只要 $K(\cdot)$ 是连续的、在待估点附近的局部样本有更大的权重，都可以作为一个合适的候选，并通过 $K(\cdot/h)$ 加入窗宽的方式控制衰减速度。所以我们将这一类函数下一个定义。

Definition 2 (Kernel function). 一个函数 $K: \mathbb{R} \mapsto \mathbb{R}^+$ ，如果满足：

$$(1) \int_{-\infty}^{\infty} K(x)dx = 1, \quad (2) \int_{-\infty}^{\infty} xK(x)dx = 0, \quad (3) \int_{-\infty}^{\infty} x^2K(x)dx < \infty$$

就被称作核函数。采用方程 (2) 得到的估计器 $\hat{f}$ ，也被称为核回归。

1.3 局部回归 (Local Regression)

回顾我们的任务：在样本 $(x_i, y_i)_{i=1}^n$ 中，我们观察到 $y \approx f(x)$ ，所以想要估计该函数。如果采用损失函数的思路，我们很自然想到最小化 $\min_f \left\{ \sum_{i=1}^n [y_i - f(x_i)]^2 \right\}$ ，再代入 f 具体形式求解，比如 $f(x_i) = \beta_0 + \beta_1 x_i$ ，线性回归/多项式回归，我们都是这样做的。

但如前文所说，局部回归是另一套逻辑：先固定待估点 $x \in \mathbb{R}$ ，我们的目标是估计这个单点的 $f(x)$ ，即：逐点估计、而不是直接估出整个函数。为了适应这个目标，距离待估点更近的样本应有更大的权重。所以我们用核函数 $K(\cdot)$ 作为权重，把原有的损失函数 $\min_f \left\{ \sum_{i=1}^n [y_i - f(x_i)]^2 \right\}$ 升级为

$$\text{加权损失: } \min_f \left\{ \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right) [y_i - f(x_i)]^2 \right\}. \quad (3)$$

为了解公式 (3)，我们需要给 f 增加一些限制：在待估点 x 附近，函数 f 能近似取一些简单的模型。

我们从最简单的开始——函数 f 在待估点附近能局部常值近似，即 $f(x_i) \approx \beta_0$ 。在这个假设下，损失函数 (3) 可以进一步化简为

$$\min_{\beta_0} \left\{ \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right) (y_i - \beta_0)^2 \right\} \Rightarrow \text{对 } \beta_0 \text{ 求导，解出这个方程，就有 } \hat{f}(x) = \hat{\beta}_0 = \frac{\sum_{i=1}^n K\left(\frac{x-x_i}{h}\right) y_i}{\sum_{j=1}^n K\left(\frac{x-x_j}{h}\right)}.$$

这正是核回归 $\hat{f}(x)$ 的显式公式。所以本质上，核回归是加权损失 (3) 在“局部常数”限制下的最优解。这也是他被称作局部常数回归 (local constant) 的原因。

Remark. 代入时，我们把所有的 $f(x_i)$ 都换成了 β_0 ，虽然这看起来像是说“所有样本点都是同一个常数”，但实则不是！由于权重函数 $K\left(\frac{x-x_i}{h}\right)$ 的存在，损失函数 (3) 中只有待估点 x 局部样本相关的项在起作用，而远离待估点的样本权重几乎为 0、不参与估计。所以我们只是假设了“待估点 x 局部常数近似”，而具体多局部，决定于窗宽 h 。

现在我们扩展一步，在待估点附近用直线近似，即 $f(x_i) \approx \beta_0(x_i) + \beta_1(x_i) \cdot x_i$ （和线性回归不同，函数 f 在不同的 x 处，有不同的斜率和截距，所以我写了 $\beta_1(x_i)$ ，而不是 β_1 ），那么损失函数 (3) 会写成

$$\min_{\beta_0, \beta_1} \left\{ \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right) [y_i - (\beta_0 + \beta_1 x_i)]^2 \right\} \Rightarrow \text{挑战: 你能快速想到 } \hat{\beta} := (\hat{\beta}_0, \hat{\beta}_1)^\top \text{ 的显式解吗 (它有吗)?}$$

答案是有的：把权重再次写成 w_i ，单看这个损失函数 $\left\{ \sum_{i=1}^n w_i [y_i - (\beta_0 + \beta_1 x_i)]^2 \right\}$ ，它是一个 weighted least square，所以我们只需代入 WLS 的公式，就可以快速解出 $\hat{\beta}$ 。具体来说：

- (i) 记数据矩阵为 $X \in \mathbb{R}^{n \times 2}$ ，其第一列为 1，第二列为 $(x_1, \dots, x_n)^\top$ ；记 response vector 为 $Y = (y_1, \dots, y_n)^\top$ ；
- (ii) 算出各样本权重 $K\left(\frac{x-x_i}{h}\right)$ ，记权重矩阵 $W(x) = \text{diag} \left[K\left(\frac{x-x_1}{h}\right), \dots, K\left(\frac{x-x_n}{h}\right) \right]$ ；

(iii) 代入 WLS 公式，算出显式解 $\hat{\beta}(x) = [X'W(x)X]^{-1}X'W(x)Y$;

(iv) 最终，估计器可以写为 $\hat{f}(x) = \hat{\beta}_0(x) + \hat{\beta}_1(x) \cdot x$ ，其中 $\hat{\beta}_0(x)$ 和 $\hat{\beta}_1(x)$ 在 $\hat{\beta}(x)$ 中算出。

这个模型就是局部线性回归 (local linear regression)。我们可以很自然地扩展到局部多项式：在待估点 x 附近，用多项式近似样本 $f(x_i) \approx \beta_0 + \beta_1 x_i + \cdots + \beta_p x_i^p$ ，后续计算方法都和局部线性师承一脉。

Remark. 如果我们对比线性模型（全局/常规）和局部线性模型，他们的区别在于

- 损失函数不同：针对待估点 x ，线性模型给所有样本的权重相同，而局部线性模型给更近的样本更大的权重；
- 这局部加权让系数 $\hat{\beta}(x)$ 与待估点 x 本身相关，进一步导致局部线性模型拥有以下两个特征。
- 第一，局部线性模型本身并不是线性函数，从这一项 $\hat{\beta}_1(x) \cdot x$ 就可以看出来。其实不仅如此，局部常数回归 (local constant) 也已不是线性函数，从它的显式解 (2) 也能看出。
- 第二，计算量大，因为我们又只能逐点计算 $\hat{f}(x)$ （我们在 k -NN 已经提到过）。